

Few-shot адаптация SmolVLA на LIBERO

Mikhail Orekhov

Тестовое задание в T-Lab, T-Банк

[Репозиторий на GitHub](#)

Август 2026

1 Постановка задачи и сетап

Цель работы — сдвинуть cost curve адаптации SmolVLA к новой задаче LIBERO: повысить success rate при фиксированном числе целевых демонстраций (0, 5, 10 и 25). В качестве стартовой модели использован lerobot smolvla_base. Она состоит из предобученной VLM и action expert, который предсказывает непрерывный чанк действий conditional flow matching [1]. В экспериментах VLM заморозена; обучаются action expert и разрешённые в конфигурации action/state projectors. Модель предсказывает 50 действий, но в среде исполняется одно действие перед следующим наблюдением.

Для seen-претрейна я использовал фиксированное стратифицированное подмножество из 40 задач канонического libero_90: 20 kitchen, 13 living room и 7 study-задач. На каждую задачу взяты все 50 демонстраций; всего в seen-пуле 2000 эпизодов. Подмножество было выбрано до получения target-результатов, не содержит демонстраций libero_goal и покрывает все три домена. Такое ограничение позволило оставить вычислительный бюджет на два seen seed, полную baseline-сетку и абляции. Исходные HDF5-демонстрации читаются on-the-fly; порядок target-демо фиксирован числовым ID demo_0, ..., demo_24.

Целевые задачи — первые три задачи libero_goal по ID бенчмарка: *open the middle drawer of the cabinet*, *put the bowl on the stove* и *put the wine bottle on top of the cabinet*. Во всех итоговых точках используются два train seed (0, 1), 20 online rollouts на task-seed и одинаковые initial-state seeds 10000, ..., 10019. Метрика в таблицах — success rate, усреднённый по двум train seed и трём target задачам.

2 Seen-претрен, zero-shot и baseline

Seen-претрен длился 10 000 optimizer updates с effective batch size 32. Использовались AdamW ($\text{lr} = 10^{-4}$, $\beta = (0.9, 0.95)$), linear warmup 1 000 updates и cosine decay. Для каждой target-точки baseline дообучается 2 000 updates с теми же оптимизатором, trainable modules, preprocessing и action interface; warmup составляет 250 updates. Таким образом, baseline — именно наивный fine-tune seen-checkpoint на первых 5/10/25 демонстрациях одной target-задачи без replay, дополнительных loss или аугментаций.

Zero-shot success равен 0% на всех трёх target-задачах для обоих seen seed. В language-control проверке на task 0 инструкция была заменена инструкцией task 1; результат также равен 0%. Это не говорит о том, что модель игнорирует язык, а лишь показывает, что в данном zero-shot режиме замена инструкции не меняет наблюдаемый success.

Таблица 1: Зафиксированная baseline cost curve. Значения task — среднее по двум train seed; для budgets 5/10/25 в скобках приведён 95% Wilson interval по 40 rollout outcomes.

Budget (demos)	Task 0	Task 1	Task 2	Mean
0	0.0	0.0	0.0	0.0
5	27.5 [16.1, 42.8]	100.0 [91.2, 100.0]	37.5 [24.2, 53.0]	55.0
10	37.5 [24.2, 53.0]	90.0 [76.9, 96.0]	67.5 [52.0, 79.9]	65.0
25	45.0 [30.7, 60.2]	95.0 [83.5, 98.6]	70.0 [54.6, 81.9]	70.0

Важно отметить, что task 1 близка к потолку уже при пяти демонстрациях, поэтому улучшение метода следует интерпретировать по средней cost curve и по задачам 0 и 2.

3 Предсказания

Replay buffer. В replay-методе target и seen demonstrations смешиваются в отношении 3 : 1 при неизменном effective batch size 32. Предсказание: replay уменьшит забывание seen-датасета и улучшит адаптацию на target-задачах. Наибольший эффект ожидается при бюджете 5 демонстраций, прежде всего на task 0 и task 2; при больших бюджетах ожидается меньший, но положительный прирост. Эта гипотеза мотивирована multi-task адаптацией с сохранением разнообразного robot prior [2, 3].

L2-SP. L2-SP не использует seen-демонстрации в target fine-tune. Перед адаптацией сохраняется копия θ_{seen} всех trainable параметров, а loss имеет вид

$$\mathcal{L} = \mathcal{L}_{\text{flow}} + \lambda \sum_{p \in \mathcal{P}} \|p - p_{\text{seen}}\|_2^2,$$

где $\mathcal{P}$ — множество trainable параметров. В экспериментах $\lambda = 10^{-2}$. Предсказание: L2-SP даст эффект, похожий на replay, но без уменьшения количества target-минибатчей. Аналогично replay наибольший прирост ожидается при бюджете 5 демонстраций; при бюджетах 10 и 25 также ожидается меньший, но положительный эффект.

LoRA. LoRA — parameter-efficient способ адаптации, мотивированный стремлением сохранить предобученные представления при малом числе target-демонстраций [4]. Предсказание: ограничение числа обучаемых степеней свободы снизит переобучение и даст наибольший выигрыш в low-budget режиме, особенно при 5 демонстрациях.

4 Результаты адаптации

Replay buffer. Screening на task 0, budget 5, seeds 0 и 1, а также task 2, budget 5, seed 0 не дал устойчивого улучшения относительно baseline. Поэтому replay не запускался на полной сетке. Это предварительное наблюдение, а не доказательство отсутствия эффекта.

L2-SP. Полная сетка L2-SP использует те же два seen-checkpoint, первые 5/10/25 target demonstrations, 2000 target updates и fixed-RNG evaluation, что и baseline. Каждая ячейка ниже — среднее по двум train seed и 20 rollout’ам на seed (всего 40 rollout’ов на задачу и budget). Стрелка показывает переход от baseline к L2-SP; в скобках приведена разница в percentage points.

Таблица 2: Сравнение baseline и L2-SP success rate (%).

Budget	Task 0	Task 1	Task 2	Mean over tasks
5	27.5 → 42.5 (+15.0)	100.0 → 95.0 (−5.0)	37.5 → 35.0 (−2.5)	55.0 → 57.5 (+2.5)
10	37.5 → 67.5 (+30.0)	90.0 → 92.5 (+2.5)	67.5 → 72.5 (+5.0)	65.0 → 77.5 (+12.5)
25	45.0 → 55.0 (+10.0)	95.0 → 92.5 (−2.5)	70.0 → 67.5 (−2.5)	70.0 → 71.7 (+1.7)

L2-SP не дал согласованного улучшения на всех бюджетах. На budget 10 средний прирост составляет +12.5 п.п. и в основном обусловлен task 0 (+30.0 п.п.). При budget 5 и 25 средние изменения составляют лишь +2.5 и +1.7 п.п.; они сопровождаются разнонаправленными изменениями между задачами. Для этих двух budget 95%-ные Wilson intervals task-level оценок L2-SP и baseline перекрываются. Поэтому результат не поддерживает исходное предсказание о сильном и устойчивом преимуществе L2-SP именно в low-budget режиме; в частности, перекрытие интервалов не следует трактовать как формальный тест отсутствия эффекта.

LoRA. Для проверки гипотезы о переобучении в наиболее дефицитном режиме LoRA была запущена на полной сетке budgets 5/10/25. LoRA адаптирует action-expert attention q/v projections и action/state projections с rank 8, $\alpha = 16$ и dropout 0.05.

Таблица 3: Сравнение baseline и LoRA success rate (%). Каждая ячейка — среднее по двум train seed и 20 rollout’ам на seed; в скобках разница в percentage points.

Budget	Task 0	Task 1	Task 2	Mean over tasks
5	27.5 → 65.0 (+37.5)	100.0 → 92.5 (−7.5)	37.5 → 65.0 (+27.5)	55.0 → 74.2 (+19.2)
10	37.5 → 60.0 (+22.5)	90.0 → 92.5 (+2.5)	67.5 → 57.5 (−10.0)	65.0 → 70.0 (+5.0)
25	45.0 → 65.0 (+20.0)	95.0 → 95.0 (0.0)	70.0 → 62.5 (−7.5)	70.0 → 74.2 (+4.2)

Наибольший наблюдаемый прирост LoRA составляет +19.2 п.п. при budget 5 и обусловлен task 0 и task 2. На budget 10 и 25 средние сдвиги уменьшаются до +5.0 и +4.2 п.п.: LoRA стабильно улучшает task 0, но уступает baseline на task 2. Task 1 близка к потолку и не даёт пространства для систематического выигрыша. Таким образом, результат поддерживает предсказание о наибольшей полезности LoRA в low-budget режиме, но не доказывает универсального преимущества на каждой задаче и каждом budget: для каждого метода остаются только два независимых training seed.





Рис. 1: Cost curves методов адаптации: средний success rate по трём target-задачам LIBERO.

5 Разбор фейлов



Baseline, task 0, budget 5



L2-SP, task 0, budget 5



Baseline, task 2, budget 5

Baseline, task 0, budget 5, seed 0: контакт с ручкой без открытия. Задача — открыть средний ящик шкафа. Конечный эффектор подходит к ручке среднего ящика вплотную, но не выполняет устойчивого захвата и тягового движения; ящик остаётся закрытым. Моя гипотеза состоит в том, что модель верно локализует цель, но не умеет надёжно перейти от визуального контакта к физическому взаимодействию. Альтернативное объяснение — небольшая ошибка оценки 6D-позы ручки: визуально gripper близок, но в действительности не занимает захватную конфигурацию.

Чтобы различить эти объяснения, я бы записал на тех же initial states позу end-effector, команду и апертуру gripper, расстояние до ручки и положение сустава ящика. Если gripper получает команду закрытия вблизи ручки, а ящик не смещается, это поддержит гипотезу о контакте/тяге. Если же минимальное расстояние и ориентация заметно отличаются от expert trajectory, причиной скорее является геометрическая локализация цели.

L2-SP, task 0, budget 5, seed 0: выбор верхнего вместо среднего ящика. Несмотря на инструкцию “open the middle drawer of the cabinet” робот направляется к области верхнего ящика и не открывает средний. Возможно L2-SP сохранил сильный seen-prior на манипуляции с верхним ящиком и недостаточно адаптировал spatial grounding слов *middle* и *top*. альтернативой остаётся ошибка визуальной локализации ящиков из-за ракурса или частичного перекрытия.

Различающий эксперимент — на одном и том же наборе initial states подать две инструкции, отличающиеся только словом *middle/top*, и сравнить первые траектории end-effector и смещение суставов обоих ящиков с baseline. Если L2-SP систематически идёт к верхнему ящику при обеих инструкциях, а baseline меняет цель, это поддержит гипотезу о слабом связывании языка с действием. Если выбор ящика меняется вместе с ракурсом, но не с текстом, более вероятна ошибка визуально-пространственного восприятия.

Baseline, task 2, budget 5, seed 0: неудачный захват бутылки. В задаче “put the wine bottle on top of the cabinet” gripper подходит к бутылке, однако при попытке захвата контакт опрокидывает её до закрытия gripper. После этого робот продолжает траекторию подъёма и размещения и раскрывает gripper у верхней части шкафа,

несмотря на отсутствие бутылки. Первая гипотеза состоит в неточной геометрии захвата: положение или ориентация gripper либо направление движения непосредственно перед захватом приводят к боковому контакту и опрокидыванию бутылки. Вторая гипотеза состоит в том, что после неудачного захвата policy недостаточно учитывает изменившееся состояние объекта и продолжает движение к месту размещения вместо повторной попытки захвата.

Для проверки первой гипотезы я бы сравнил позы бутылки и gripper и направление движения непосредственно перед контактом с expert trajectory. Систематическое отличие положения или ориентации gripper перед опрокидыванием поддержит гипотезу об ошибке захвата. Для проверки второй гипотезы я бы отдельно анализировал действия после падения бутылки. Если после получения нового наблюдения, в котором бутылка уже лежит вне gripper, policy продолжает подъём и движение к месту размещения без попытки вернуться к объекту, это поддержит гипотезу о недостаточной коррекции поведения после неудачного захвата.

6 Бонусная задача

Бонусная задача не выполнялась: доступный compute budget и время были направлены на два train seed, полную baseline-сетку и проверку методов адаптации в основной части задания.

7 Summary и обсуждение

Предсказания против результатов. Предсказание для L2-SP не подтвердилось в исходной форме. Я ожидал наибольший выигрыш при пяти демонстрациях, однако средний прирост составил лишь +2.5 п.п. Наиболее заметный эффект получен при budget 10 на task 0: 37.5% → 67.5% (+30.0 п.п.; оба train seed улучшаются), а средний прирост по трём задачам составил +12.5 п.п. При budget 25 средний сдвиг +1.7 п.п. находится в пределах доступной неопределённости.

Предсказание для LoRA подтверждается на полной сетке, но прежде всего в low-budget режиме. При пяти демонстрациях средний success повышается с 55.0% до 74.2%. На task 0 LoRA с пятью демонстрациями достигает 65.0%, превосходя baseline даже при 25 демонстрациях (45.0%), а на task 2 результат 65.0% близок к baseline при десяти демонстрациях (67.5%). При budgets 10 и 25 LoRA сохраняет среднее преимущество +5.0 и +4.2 п.п., однако оно меньше и сопровождается ухудшением task 2. Следовательно, убедительный сдвиг cost curve влево наблюдается главным образом при пяти демонстрациях и не должен интерпретироваться как одинаковый эффект для всех задач.

Кладбище идей.

Seen replay. Replay был отвергнут после ограниченного screening, который не дал устойчивого улучшения на двух сложных target-задачах. При имеющемся сигнале LoRA доступный compute был направлен на более информативную проверку low-rank adaptation.

Замена action head. Замена action head не была включена в основную сетку: SmolVLA уже использует нативный continuous flow-matching action expert. Проверка другой головы потребовала бы отдельного baseline, иной objective и существенно расширила бы compute budget, поэтому сравнение перестало бы изолировать few-shot adaptation.

FiberTune. FiberTune регуляризует промежуточные visual tokens, разделяя action-predictive и остаточные направления представлений. Для SmolVLA метод потребовал бы доступа к промежуточным токенам, выбора teacher/layer и отдельной абляции с разморозкой VLM, поэтому он был исключён до реализации [5].

Неожиданное наблюдение. Наивный baseline достигает 100% на task 1 уже при budget 5 для обоих train seed, тогда как task 0 и task 2 сохраняют большой запас для улучшения. Вероятное объяснение — task 1 требует менее точной последовательности манипуляций: размещение чаши на плите допускает большую погрешность конечной позиции, тогда как открытие ящика требует точного контакта с ручкой, а размещение бутылки на шкафу — устойчивого захвата и более длинной последовательности переноса.

Список литературы

1. M. Shukor et al. *SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics*. arXiv:2506.01844, 2025. <https://arxiv.org/abs/2506.01844>
2. Octo Model Team. *Octo: An Open-Source Generalist Robot Policy*. arXiv:2405.12213, 2024. <https://arxiv.org/abs/2405.12213>
3. K. Black et al. π_0 : *A Vision-Language-Action Flow Model for General Robot Control*. arXiv:2410.24164, 2026. <https://arxiv.org/abs/2410.24164>
4. Y. Jiang et al. *VLA-GSE: Boosting Parameter-Efficient Fine-Tuning in VLA with Generalized and Specialized Experts*. arXiv:2605.06175, 2026. <https://arxiv.org/abs/2605.06175>
5. H. Lin et al. *FiberTune: Preserving Action-Fiber Visual Residuals in Vision-Language-Action Fine-Tuning*. arXiv:2606.08653, 2026. <https://arxiv.org/abs/2606.08653>
6. M. J. Kim et al. *OpenVLA: An Open-Source Vision-Language-Action Model*. arXiv:2406.09246, 2024. <https://arxiv.org/abs/2406.09246>
7. M. J. Kim, C. Finn, and P. Liang. *Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success*. arXiv:2502.19645, 2025. <https://arxiv.org/abs/2502.19645>
8. X. Guo et al. *PriorVLA: Prior-Preserving Adaptation for Vision-Language-Action Models*. arXiv:2605.10925, 2026. <https://arxiv.org/abs/2605.10925>
9. C. Xu, E. Yu, J. Xuan, and J. Lu. *VGAS: Value-Guided Action-Chunk Selection for Few-Shot Vision-Language-Action Adaptation*. arXiv:2602.07399, 2026. <https://arxiv.org/abs/2602.07399>
10. D. M. Nguyen et al. *FOCA: Future-Oriented Conditioning for Data-Efficient Vision-Language-Action Adaptation*. arXiv:2606.20867, 2026. <https://arxiv.org/abs/2606.20867>